

Санкт–Петербургский государственный университет

ТРЕТЬЯКОВ Даниил Александрович

Выпускная квалификационная работа

Исследование эффективности непрерывного обучения с использованием сетей Колмогорова-Арнольда в задаче распознавания образов

Уровень образования: бакалавриат

Направление 01.03.02 «Прикладная математика и информатика»

Основная образовательная программа СВ.5005.2021 «Прикладная математика, фундаментальная информатика и программирование»

Научный руководитель:

профессор кафедры компьютерного моделирования и многопроцессорных систем, д.т.н. Дегтярев Александр Борисович

Рецензент:

доцент кафедры компьютерного моделирования и многопроцессорных систем, к.ф.-м.н. Корхов Владимир Владиславович

Санкт-Петербург

2025 г.

Содержание

Введение	3
Постановка задачи	7
Обзор литературы	10
Глава 1. Анализ существующих подходов к преодолению катастрофического забывания	12
1.1. Подход с использованием регуляризации	13
1.1.1 Весовая регуляризация (Prior Focused)	13
1.1.2 Функциональная регуляризация (Data Focused)	15
1.2. Подход с изменением архитектуры	16
1.2.1 Фиксированная архитектуры (Fixed Network)	16
1.2.2 Динамическая архитектура (Dynamic Network)	17
1.3. Подход с воспроизведением опыта	19
1.3.1 Повторение (Rehearsal)	19
1.3.2 Псевдоповторение (Pseudo Rehearsal)	19
1.3.3 С градиентными ограничениями (Constrained)	20
Глава 2. Построение усовершенствованных моделей на базе архитектуры KAN	22
2.1. Подход с использованием регуляризации	22
2.2. Подход с изменением архитектуры	22
2.3. Подход с воспроизведением опыта	22
Глава 3. Применение усовершенствованных моделей в задачах непрерывного обучения	23
3.1. Обучение с перестановкой признаков	23
3.2. Инкрементальное обучение классам	23
Глава 4. Анализ экспериментов	24
Выводы	25
Заключение	26
Список литературы	27
Приложение	31

Введение

В последние десятилетия нейронные сети стали одним из ключевых компонентов современных интеллектуальных систем. Способность аппроксимировать сложные зависимости и выявлять скрытые паттерны в больших объемах данных делает их эффективными инструментами в сложных исследовательских и прикладных задачах. Именно нейронные сети сделали возможным появление алгоритмов, превосходящих человеческие возможности в узкоспециализированных задачах, где люди традиционно считались непревзойденными, например, в распознавании изображений и речи, играх и стратегиях, медицинской диагностике.

Однако в отличие от человека, для нейронной сети, после того как она была обучена выполнению определенной задачи, например, классификации деревьев, обучение дополнительной задаче, например, классификации птиц, оказывается затруднительным. Это связано с тем, что при добавлении новой задачи типичная нейронная сеть склонна «забывать» предыдущую. В связи с этим, одним из актуальных направлений в развитии нейронных сетей является непрерывное обучение - подход, при котором модель способна обучаться и адаптироваться на протяжении всего срока эксплуатации с целью поддержания своей производительности при изменяющихся условиях окружающей среды и данных, без необходимости полного переобучения. Потребность в подобных моделях особенно сильна в рекламной индустрии, финансовой аналитике, робототехнике и кибербезопасности.

Как правило, в исследованиях, посвященных методам преодоления катастрофического забывания, рассматривается многослойный перцептрон (Multi-Layer Perceptron, MLP). Это связано с тем, что MLP - одна из самых простых и универсальных архитектур нейронных сетей, которая вдобавок обладает важным свойством: способностью выступать в роли универсального аппроксиматора. Благодаря этому MLP-блоки используются как составная часть многих современных архитектур, таких как CNN, RNN и трансформеры, но из-за пересечения кодирующих подпространств часто оказываются одними из наиболее уязвимых перед воздействием катастрофического забывания. Вследствие повсеместной встречаемости полносвязных слоев методы,

направленные на решение проблемы катастрофического забывания в многослойном перцептроне, могут косвенно повлиять на решение этой проблемы и для многих других нейронных сетей.

Несмотря на то, что в борьбе с катастрофическим забыванием в многослойном перцептроне были достигнуты определенные успехи, в последние месяцы растёт интерес к многообещающей альтернативе, также подходящей на роль универсального аппроксиматора - нейронной сети Колмогорова-Арнольда (Kolmogorov-Arnold Network, KAN). Ключевые различия между архитектурами MLP и KAN представлены на рисунке 1: в то время как в многослойном перцептроне функции активации фиксированы и применяются к выходам нейронов, в KAN функции активации применяются на месте линейных весов в MLP, являются обучаемыми и могут быть параметризованы, например, с помощью базисных сплайнов. Теоретической основой для MLP служит теорема Цыбенко (также известная как Универсальная теорема аппроксимации), а в случае KAN источником вдохновения стала теорема о представлении Колмогорова—Арнольда. Главная причина, по которой KAN





Модель	Multi-Layer Perceptron (MLP)	Kolmogorov-Arnold Network (KAN)
Теорема	Универсальная теорема аппроксимации	Теорема о представлении Колмогорова-Арнольда
Формула слоя	$f(\mathbf{x}) \approx \sum_{i=1}^{N(\epsilon)} a_i \sigma(\mathbf{w}_i \cdot \mathbf{x} + b_i)$	$f(\mathbf{x}) = \sum_{q=1}^{2n+1} \Phi_q \left(\sum_{p=1}^n \phi_{q,p}(x_p) \right)$
Структура слоя		
Формула сети	$\text{MLP}(\mathbf{x}) = (\mathbf{W}_3 \circ \sigma_2 \circ \mathbf{W}_2 \circ \sigma_1 \circ \mathbf{W}_1)(\mathbf{x})$	$\text{KAN}(\mathbf{x}) = (\Phi_3 \circ \Phi_2 \circ \Phi_1)(\mathbf{x})$
Структура сети		

Рис. 1: Сравнение MLP и KAN. Адаптировано из [10], лицензия: CC BY 4.0.

представляет интерес с точки зрения применения в условиях непрерывного обучения, заключается в возможности параметризации функции активации

таким образом, чтобы изменение параметров в одной области пространства не влияло на другие области. Это возможно, например, при использовании В-сплайнов, обладающих локальной поддержкой. Поскольку обучение на новых данных будет затрагивать лишь несколько соседних параметров, информация, сохранённая в остальных параметрах, остается нетронутой. В MLP, напротив, даже отдельные изменения могут повлиять на информацию, хранящуюся в отдалённых друг от друга параметрах.

Для демонстрации преимуществ, связанных с локальной поддержкой функции активации, предлагается рассмотреть простейшую задачу одномерной регрессии, детали которой приведены на рисунке 2: обучение состоит из 5 тренировочных сессий, в каждой из которых используются исключительно объекты из соответствующей части набора данных, также разделённого на 5 частей. Можно заметить, что в данной задаче KAN изменяет только те параметры, которые отвечают за аппроксимацию зависимости в данных текущей тренировочной сессии, в то время как MLP оказывается не способен сохранить информацию, полученную в течение предыдущих тренировочных сессий. Рассмотренная задача является лишь упрощённым примером, в ко-




Рис. 2: Простейшая задача непрерывного обучения: по горизонтали показаны 5 последовательных тренировочных сессий одномерной регрессии («Тренировочная сессия 1-5»); по вертикали — три строки: «Данные» (данные, используемые в текущей тренировочной сессии, выделены чёрным, остальные серым), «KAN» (предсказания сети KAN) и «MLP» (предсказания сети MLP). Адаптировано из [10], лицензия: CC BY 4.0.

тором особенности архитектуры KAN позволили существенно повлиять на

эффективность непрерывного обучения. В прикладных задачах размерность параметрического пространства нейронных сетей, как правило, значительно выше, и сохранение свойства локальности изменений параметров оказывается под вопросом.

Поскольку необходимым условием для достижения максимальной эффективности непрерывного обучения является использование нейронных сетей в сочетании с методами противодействия катастрофическому забыванию, тестирование оригинальной архитектуры KAN без этих методов не позволит в полной мере оценить перспективы её применения в непрерывном обучении. Поэтому главная цель данной работы - адаптировать методы противодействия, разработанные для многослойного перцептрона, для использования в сетях Колмогорова-Арнольда и выяснить, позволяет ли локальная природа KAN упростить или усилить классические приёмы, лежащие в основе этих методов. С этой целью эффективность полученных моделей в условиях непрерывного обучения на задаче распознавания образов исследуется с использованием набора данных CUB200, обладающего свойствами, характерными для прикладных задач.

Полный исходный код, а также графические материалы, использованные в работе, размещены в публичном репозитории на GitHub [25].

Постановка задачи

Рассматривается процесс непрерывного обучения в задаче многоклассовой классификации в признаковом пространстве $\mathcal{X} \subseteq \mathbb{R}^d$ с множеством классов $\mathcal{Y} = \{1, \dots, C\}$, где d - размерность признакового пространства, C - число классов. Дана обучающая выборка D , состоящая из размеченных объектов, разбитых на T частей, соответствующих тренировочным сессиям B_t , то есть $D = \{B_t\}_{t=1}^T$. Каждая тренировочная сессия состоит из N_t объектов (N_t может изменяться между сессиями). Таким образом, $B_t = \{(x_i, y_i)\}_{i=1}^{N_t}$, где $x_i \in \mathcal{X}$, $y_i \in \mathcal{Y}$. Предполагается, что элементы в каждой тренировочной сессии независимы и имеют одинаковое совместное распределение данных и меток классов $\mathbb{D}_t$, $t = 1, \dots, T$. Нейронная сеть $f_\theta : \mathcal{X} \rightarrow \mathbb{R}^C$ с параметрами $\theta \in \mathbb{R}^{|\theta|}$ последовательно обучается решению T задач, используя объекты текущей тренировочной сессии. Иначе говоря, в момент времени t модели предоставлены лишь данные из B_t .

Требуется получить модель f_θ , способную сохранять информацию, полученную в предыдущих тренировочных сессиях обучения, и одновременно эффективно усваивать новые знания, приобретённые в течение последней тренировочной сессии. Для оценки качества обучения модели в текущей тренировочной сессии используется следующий функционал:

$$Q(f_\theta, B_t) = \frac{1}{N_t} \sum_{(x,y) \in B_t} \mathcal{L}(f_\theta(x), y),$$

где $\mathcal{L}$ - кросс-энтропийная функция потерь. Параметры модели θ подбираются таким образом, чтобы минимизировать функционал Q . Обучение сводится к нахождению оптимальных параметров θ_t , которые сохраняются после завершения текущей тренировочной сессии и используются в качестве начальных значений в следующей:

$$\theta_t = \arg \min_{\theta} Q(f_\theta, B_t) = \arg \min_{\theta} \frac{1}{N_t} \sum_{(x,y) \in B_t} \mathcal{L}(f_\theta(x), y),$$

Для количественной оценки способности моделей противостоять катастрофическому забыванию в процессе непрерывного обучения используются

метрики, описанные в [18]:

$$\Omega_{base} = \frac{1}{T-1} \sum_{i=2}^T \frac{\alpha_{base,i}}{\alpha_{ideal}},$$

$$\Omega_{new} = \frac{1}{T-1} \sum_{i=2}^T \frac{\alpha_{new,i}}{\alpha_{ideal}},$$

$$\Omega_{all} = \frac{1}{T-1} \sum_{i=2}^T \frac{\alpha_{all,i}}{\alpha_{ideal}},$$

где:

α_{ideal} - значение метрики ассигасу на совокупности всех тестовых выборок D , полученное при оффлайн обучении модели без механизмов противодействия катастрофическому забыванию,

$\alpha_{base,i}$ - значение метрики ассигасу на тестовой выборке первой тренировочной сессии после обучения модели в i -ой тренировочной сессии,

$\alpha_{new,i}$ - значение метрики ассигасу на тестовой выборке i -ой тренировочной сессии после обучения модели на этой же тренировочной сессии,

$\alpha_{all,i}$ - значение метрики ассигасу на совокупности тестовых выборок всех предыдущих тренировочных сессий.

Таким образом, Ω_{new} измеряет способность модели использовать только что приобретенные знания, Ω_{base} измеряет способность модели удерживать в памяти знания, полученные в первой тренировочной сессии, а Ω_{all} оценивает общую эффективность использования накопленных знаний.

Цель и задачи исследования

Целью данной работы является исследование эффективности применения архитектуры KAN в сочетании с методами противодействия катастрофическому забыванию в задаче распознавания образов в условиях непрерывного обучения. Для достижения поставленной цели необходимо решить следующие задачи:

1. Изучить методы противодействия катастрофическому забыванию, разработанные для многослойного перцептрона, и выделить основные под-

ходы, лежащие в основе этих методов.

2. Адаптировать для архитектуры KAN методы, использующие разные подходы, и разработать на их основе модифицированные модели.
3. Применить оригинальную и модифицированные модели KAN в задаче распознавания образов в условиях непрерывного обучения с использованием набора данных CUB200.
4. Сравнить противодействие катастрофическому забыванию между оригинальной и модифицированными моделями и выяснить, помогает ли свойство локальной поддержки функций активации KAN повысить эффективность классических приёмов, использованных в этих моделях.
5. Проанализировать полученные результаты и оценить перспективы применения сетей Колмогорова-Арнольда в задачах непрерывного обучения.

Обзор литературы

Нейронная сеть Колмогорова-Арнольда, составляющая основу данного исследования, описана в статьях [9; 10], где вводятся архитектуры KAN и MultKAN, позиционируемые в качестве альтернативы MLP. В [10] поднимается вопрос о необходимости исследования потенциала сетей Колмогорова-Арнольда в непрерывном обучении на задачах высокой размерности, также в обеих статьях проводятся многочисленные эксперименты, демонстрирующие интерпретируемость новых архитектур и их применимость в качестве инструмента символьной регрессии. Всестороннее сравнение архитектур KAN и MLP представлено в работе [26]. В ней делается вывод о том, что KAN демонстрирует преимущество только в задаче символьной регрессии, а в остальных задачах машинного обучения, включая задачи компьютерного зрения (Computer Vision, CV), обработки естественного языка (Natural Language Processing, NLP) и обработки аудиосигналов (audio processing), уступает. В частности, показано, что в условиях непрерывного обучения официальная реализация KAN [16] полностью теряет первоначальные знания после обучения всего на трёх последовательных задачах, тогда как MLP в тех же условиях сохраняет приемлемую точность. Выводы этой статьи обусловили смещение акцентов в настоящем исследовании в сторону анализа KAN в сочетании с классическими методами противодействия катастрофическому забыванию, а не самой по себе оригинальной архитектуры, и кроме этого подтолкнули к внесению изменений в официальную программную реализацию.

Среди исследований, посвящённых непосредственно явлению катастрофического забывания в сетях Колмогорова-Арнольда следует выделить статью [11]. Её основным результатом является архитектура WiseKAN, но наибольший интерес представляют сформулированные в ней причины обострения проблемы катастрофического забывания в KAN. Первая причина - пересечение входных значений сплайна, вторая - низкая разреженность градиентов вследствие необходимости поиска компромисса между шириной слоёв нейронной сети и количеством параметров в сплайнах. Эти выводы показали необходимость рассмотрения в данном исследовании методов, основанных на использовании разреженного кодирования представлений.

Теме непрерывного обучения посвящено множество научных публикаций, однако количество монографий невелико. Изучение теоретического материала базировалось на книге [2], в которой представлен систематический обзор парадигм машинного обучения (в частности, непрерывного обучения), а также книге [17], где рассматриваются проблемы, возникающие при обработке нестационарных данных. Анализ современного состояния методов противодействия катастрофическому забыванию опирался на ряд специализированных обзоров: в [18] предложена таксономия, разделяющая подходы на регуляризацию, ансамблирование, разреженное кодирование и воспроизведение опыта. В [4] проведена параллель между искусственными нейронными сетями и мозгом, а также сгруппированы и рассмотрены основные биологические механизмы, приведшие к появлению новых алгоритмов непрерывного обучения. В [1] даётся цельный обзор: формулируются постановка задачи и теоретические основы разных подходов, а также предлагается расширенная таксономия методов и анализируется их применение в широком спектре областей (CV, NLP и другие), что делает работу актуальным срезом состояния области на 2024 год.

В результате изучения научных публикаций по теме непрерывного обучения был сформирован окончательный список методов, подлежащих адаптации для нейронных сетей Колмогорова-Арнольда: Fixed Expansion Layer (FEL), GeppNet и Elastic Weight Consolidation (EWC). Основные сведения, необходимые для их реализации, были получены из соответствующих статей [5; 7; 20], однако обновление информационной матрицы Фишера в EWC было изменено в соответствии с выводами [22], а самоорганизующаяся карта (Self-organizing map, SOM) в GeppNet заменена на Batch-SOM ([3]). Подробности реализации этих методов описаны в главе 2.

Глава 1. Анализ существующих подходов к преодолению катастрофического забывания

Поскольку явление, приводящее к потере моделью ранее выученной информации, получившее название катастрофического забывания, является основным вызовом в области непрерывного обучения, для борьбы с ним разработаны многочисленные методы, которые принято делить на несколько основных подходов. Данная работа опирается на двухуровневую схему, предложенную в [12], где выделяются три основных подхода, а также их подкатегории:

1. **Использование регуляризации:** в функцию потерь добавляются регуляризирующие члены, призванные сохранить значения важных параметров, связанных с предыдущими задачами.
2. **Изменение архитектуры:** структура нейронной сети расширяется или изменяется с целью назначения для каждой из задач отдельного набора параметров.
3. **Воспроизведение опыта:** образцы данных, встречаемых в процессе обучения, сохраняются или используются для обучения генеративной модели. Затем эти образцы (или псевдо-образцы, если использовалась генеративная модель) используются для освежения знаний модели о старых задачах.

Полная схема разбиения методов представлена на рисунке 3.

Чтобы наглядно сравнить то, как свойство локальной поддержки функций активации в KAN взаимодействует с каждой из принципиально отличающихся друг от друга стратегий противодействия катастрофическому забыванию, было принято решение адаптировать по одному методу из каждого подхода. Несмотря на упоминание в литературе современных (как правило, гибридных) методов, предпочтение отдавалось классическим алгоритмам, так как они имеют прозрачную теоретическую основу и достаточно просты для переноса в новую архитектуру, но по-прежнему выступают в качестве базовых моделей в большинстве современных исследований.



Рис. 3: Двухуровневая таксономия методов противодействия катастрофическому забыванию, предложенная в [12]. Во второй строке показаны три базовых подхода: использование регуляризации (regularization-based), изменение архитектуры (architecture-based) и воспроизведение опыта (replay-based). Ниже перечислены подкатегории, составляющие каждый из подходов.

Оставшаяся часть главы посвящена описанию принципов, лежащих в основе выделенных подходов, а также обзору алгоритмов, которые их реализуют.

1.1 Подход с использованием регуляризации

1.1.1 Весовая регуляризация (Prior Focused)

Основной принцип методов с весовой регуляризацией, таких как Elastic Weight Consolidation (EWC) [20] и Synaptic Intelligence (SI) [27], заключается в использовании новой функции потерь $\mathcal{L}_{total}$, полученной добавлением в стандартную функцию потерь $\mathcal{L}$ нового слагаемого, штрафующего за изменение

тех параметров нейронной сети, которые имели наибольшую важность для выполнения предыдущих задач. В терминах ранее введенных обозначений:

$$\mathcal{L}_{\text{total}}(f_{\theta}(x), y, \theta_{t-1}) = \mathcal{L}(f_{\theta}(x), y) + \|\theta - \theta_{t-1}\|_{\Sigma},$$

где:

θ_{t-1} - априорные значения параметров, отклонение от которых должно быть ограничено,

Σ - матрица оценок важности параметров с точки зрения их влияния на качество выполнения предыдущих задач,

$\|\cdot\|_{\Sigma}$ - взвешенная норма.

Часто используется L2-норма, при использовании которой регуляризующее слагаемое принимает вид $\frac{1}{2}(\theta - \theta_{t-1})^T \Sigma (\theta - \theta_{t-1})$. Это можно интерпретировать как наделение весов внутренним состоянием, которое определяет уровень их пластичности. Другой полезной интерпретацией является рассмотрение таких методов в качестве последовательного приближенного Байесовского вывода для параметров нейронной сети.

Одним из ключевых аспектов рассматриваемых методов считается оценка важности параметров. Распространённым подходом является использованием информационной матрицы Фишера (Fisher Information Matrix, FIM), которая показывает как небольшие изменения параметров повлияют на значение функции потерь. Как правило, для ускорения вычислительных процедур используется диагональная аппроксимация FIM, что означает предположение о независимости признаков. Вторым существенным недостатком матрицы Фишера оказалась вычислительная затратность. Вместе они привели к появлению целого ряда методов [19; 27], аппроксимирующих FIM или заменяющих её прямой подсчет эвристическими методами.

В целом, несмотря на успешное применение методов, использующих весовую регуляризацию, в некоторых задачах непрерывного обучения, считается, что они плохо подходят для задачи инкрементального обучения классам.

1.1.2 Функциональная регуляризация (Data Focused)

По аналогии с весовой регуляризацией, функциональная регуляризация добавляет новое слагаемое в функцию потерь $\mathcal{L}$. Однако эффективная и вместе с тем корректная оценка весов модели представляет большую сложность из-за комплексной взаимосвязи между поведением нейронной сети и её параметрами. Из-за этого оказывается оправданным уход от пространства параметров к оперированию ограничениями непосредственно в функциональном пространстве нейронной сети:

$$\mathcal{L}_{\text{total}}(f_{\theta}(x), y, \theta_{t-1}) = \mathcal{L}(f_{\theta}(x), y) + \langle f_{\theta}, f_{\theta_{t-1}} \rangle_{\mathcal{A}},$$

где:

$\mathcal{A}$ - множество элементов из набора входных данных, выступающих в роли якорных точек (anchor points),

$f_{\theta_{t-1}}$ - отображение, сопоставляющее каждому элементу из множества $\mathcal{A}$ (якорных точек) соответствующий выход нейронной сети с параметрами θ_{t-1} ,

$\langle \cdot, \cdot \rangle$ - мера близости на множестве $\mathcal{A}$.

Таким образом, основная цель функциональной регуляризации состоит в минимизации различий между выходами новой f_{θ} и старой $f_{\theta_{t-1}}$ нейронных сетей на множестве специальных элементов входного набора данных $\mathcal{A}$, называемых якорными точками.

Существуют различные способы измерить расхождение между функциями f_{θ} и $f_{\theta_{t-1}}$. Наибольшую популярность приобрёл использованный в алгоритме Learning without Forgetting (LwF) [14] подход с дистилляцией знаний [8]. Поскольку расхождение между f_{θ} и $f_{\theta_{t-1}}$ не обязательно измерять только в выходном пространстве нейронной сети, в некоторых работах, например [24], применяется дистилляция признаков, при которой для передачи знаний от «учителя» к «ученику» используются не только выходы сети, но и формируемые в скрытых слоях промежуточные представления (признаки).

Ещё одним важным вопросом в функциональной регуляризации является выбор якорных точек $\mathcal{A}$. Формирование этого множества при помощи случайного выбора элементов из входного набора данных может оказаться

достаточным лишь для относительно простых задач. Одно из решений состоит в использовании текущей тренировочной сессии B_t в качестве $\mathcal{A}$, как было сделано в алгоритме LwF, однако такой подход применим только в случае, если данные в разных тренировочных сессиях имеют одинаковую модальность (например, являются изображениями). Помимо этого существуют подходы, стремящиеся выбрать из каждой тренировочной сессии ограниченный набор репрезентативных в некотором смысле объектов, но вопрос оптимального выбора якорных точек во многом остается открытой проблемой.

1.2 Подход с изменением архитектуры

Рассмотренный ранее подход предназначен для обучения модели выполнению нескольких задач посредством эффективного переиспользования одного и того же набора параметров, задействованного во всех тренировочных сессиях. Однако существует другой подход: назначение для каждой из задач обособленного (возможно, непересекающегося) набора параметров с помощью изолирования их друг от друга в рамках одной модели (фиксированная архитектура) или создания новых моделей, приспособленных для решения отдельных задач (динамическая архитектура). Это позволяет избежать перезаписи информации, содержащейся в параметрах нейронной сети, тем самым снижая воздействие катастрофического забывания.

1.2.1 Фиксированная архитектуры (Fixed Network)

Основным принципом моделей с фиксированной архитектурой является изоляция параметров, используемых в разных тренировочных сессиях, для уменьшения их взаимного влияния на выученные друг другом промежуточные представления. Среди сильных сторон фиксированных сетей выделяют низкий расход памяти и относительную простоту. Однако они требуют тщательного планирования при выделении весов под каждую из задач, а также, как и сети с динамической архитектурой, они часто нуждаются в информации о текущем типе задачи в условиях инкрементального обучения задачам (task-incremental learning).

Центральным вопросом в сетях с фиксированной архитектурой явля-

ется способ разделения весов на группы: следует ли фиксировать группы заранее или позволить им формироваться в процессе обучения; выбирать расположение весов в рамках одной группы случайно или целыми блоками.

Одной из наиболее ранних попыток предложить ответ на эти вопросы стала архитектура PathNet [21]. В нём каждый слой заранее разбивается на M модулей (групп нейронов), а в процессе обучения генетическим алгоритмом ищется оптимальный маршрут (path), представляющий собой вектор индексов, указывающий, какие из $N < M$ модулей в данном слое будут активны в данной задаче. Передача сигнала происходит только между активными модулями соседних слоёв, поэтому веса остальных нейронов не участвуют ни в прямом (forward pass), ни в обратном (backward pass) проходе и не обновляются в ходе обратного распространения ошибки. Считается, что априорное разбиение параметров на группы, как у PathNet, обеспечивает высокую стабильность, но может приводить к нехватке выразительности сети из-за фрагментации параметрического пространства

В качестве отдельного направления внутри фиксированных сетей следует выделить архитектуру Fixed Expansion Layer (FEL) [5]. Её основная идея заключается в добавлении расширенного слоя с жёстко заданными, необучаемыми весами. Этот слой призван разреживать проходящие через него сигналы, благодаря чему обновление градиента в течение очередной тренировочной сессии затрагивают лишь обособленные группы параметров предыдущего слоя, что резко снижает количество нежелательных изменений в параметрах, ответственных за решения разных задач. В то же время расширенный слой остаётся фиксированным, поэтому в отличие от методов с динамической архитектурой, рассматриваемых далее, его использование не приводит к неограниченному росту числа параметров.

1.2.2 Динамическая архитектура (Dynamic Network)

Нейронные сети с динамической архитектурой можно условно разделить на две группы: модели, использующие ансамблевые методы, а также модели, использующие расширение архитектуры (network expansion).

К первой группе относятся алгоритмы, стремящиеся избежать ката-

строфического забывания посредством обучения нескольких моделей «экспертов» и комбинирования их ответов. К примеру, Learn++ [13] адаптирует классический алгоритм AdaBoost, наращивая ансамбль в течение нескольких тренировочных сессий и делая итоговое предсказание с помощью взвешенного голосования. Недостатком Learn++ является линейный рост требуемой для хранения весов памяти и увеличение времени инференса. Развитие этого подхода было предложено в [15], где вводится весовая схема, способная одновременно как добавлять, так и исключать экспертов в зависимости от их полезности в последних тренировочных сессиях. Особое место среди трудностей, возникающих при разработке методов, представляющих собой ансамбль экспертов, занимает необходимость выбора эксперта для получения предсказания.

В свою очередь, модели, использующие расширение архитектуры, в каждой тренировочной сессии добавляют в изначальную архитектуру новые нейроны или целые слои, а параметры, отвечающие за ранее выученные задачи, «замораживают». Такой приём подавляет катастрофическое забывание, однако, как и в случае с предыдущей группой, приводит к линейному росту объёма памяти и вычислительных издержек. Ранние методы, такие как PNN [23], имели простой принцип, интегрируя в архитектуру новые цепочки нейронов (нейронные сети единичной ширины), фиксируя веса предыдущих столбцов и обучая новые веса переиспользовать полезные признаки, сформировавшиеся в течение предыдущих тренировочных сессий. Такие методы имели типичную для моделей с динамической архитектурой проблему с линейным ростом затрачиваемых ресурсов и требовали выбора правильных столбцов для получения предсказаний. Результатом дальнейших исследований стал гибридный метод Progress & Compress (P & C) [22], объединивший в себе методы PNN и EWC и добившийся работы с использованием постоянного объёма памяти.

1.3 Подход с воспроизведением опыта

1.3.1 Повторение (Rehearsal)

Главный принцип методов с повторением заключается в сохранении небольшого подмножества элементов предыдущих тренировочных сессий и периодическом включении их в текущую выборку данных. Классическим примером, реализующим этот принцип является алгоритм Experience Replay (ER) [6]. Для повышения репрезентативности сохраняемых экземпляров, в случае инкрементального обучения классам, стремятся выбирать из тренировочных сессий такие примеры, которые наиболее близки к среднему представлению класса в признаковом пространстве. В других задачах непрерывного обучения отбор репрезентативных объектов может оказаться затруднителен.

Известным примером архитектуры с повторением является GeppNet [7], реализующая отбор репрезентативных объектов через использование самоорганизующейся карты (self-organising map, SOM), выступающей в роли буфера долгосрочной памяти и организующая входные векторы на двумерной решётке с сохранением топологии исходного распределения.

Как правило, методы с повторением оказываются очень эффективны и сравнительно просты в реализации, однако их серьёзным недостатком является хранение реальных примеров, которое предполагает линейный рост объема необходимой памяти и может нарушать требования безопасности при обработке конфиденциальных данных.

1.3.2 Псевдоповторение (Pseudo Rehearsal)

В основе идеи псевдоповторения лежит воспроизведение искусственных примеров из предыдущих тренировочных сессий, полученных с помощью генеративных моделей и последующее объединение этих примеров с текущим набором данных в процессе обучения, что позволяет избежать явного хранения реальных образцов.

Искусственные примеры и соответствующие метки создаются посредством пропускания случайного шума через отдельную генеративную модель (например, GAN), но при увеличении роста сложности генерация репре-

зентативных образцов может оказаться чрезвычайно трудной задачей. Такие псевдо-образцы часто не полностью отражают истинное распределение прошлых данных, поэтому отдельным направлением исследований является поиск способов сохранения способности генераторов синтезировать репрезентативные примеры. Кроме того, их качественное обучение и поддержка требуют значительных ресурсов и времени, что не всегда реализуемо на практике.

Таким образом, основное преимущество методов с псевдоповторением (pseudo rehearsal) перед методами с повторением (rehearsal) сводится к отсутствию необходимости хранения реальных данных, а значит, к снижению требований к объему памяти и к повышению безопасности при работе с чувствительными данными. Взамен появляется необходимость обучения отдельной генеративной нейронной сети, которая сама по себе будет подвержена катастрофическому забыванию и потребует использования регуляризации или других методов предотвращения появления смещений в её априорном распределении.

1.3.3 С градиентными ограничениями (Constrained)

Методы с градиентными ограничениями также сохраняют в буфер подвыборку примеров из предыдущих задач и используют их для вычисления градиента функции потерь по этим примерам при обучении на новой задаче. Если градиент в текущей тренировочной сессии конфликтует с градиентами буфера (то есть их скалярное произведение отрицательно), выполняется проекция нового градиента на выпуклую область, образованную этими градиентами, чтобы не избежать потери производительности в предыдущих задачах.

Наибольшую популярность среди constrained-методов приобрёл алгоритм Averaged Gradient Episodic Memory (A-GEM), где для ускорения вычислительной процедуры вместо градиентов функции потерь по каждому из содержащихся в буфере образцов используется усреднённый градиент буфера. Если градиент текущей задачи конфликтует с этим усреднённым градиентом, то градиент текущей задачи проецируется на гиперплоскость, ортогональную градиенту из буфера.

К преимуществам методов с градиентными ограничениями можно отнести архитектурную простоту и возможность выбора между формальными гарантиями невозрастания потерь на прошлых задачах (при вычислении градиентов по каждому из примеров в буфере памяти) и высокой производительности (при использовании упрощённых вариантов по типу A-GEM). Недостатки обусловлены главным образом наличием буфера памяти: требуется линейное по числу тренировочных сессий количество ресурсов, имеются проблемы с конфиденциальностью и необходимо решать, какие примеры хранить в памяти, чтобы содержание буфера было репрезентативным.

Глава 2. Построение усовершенствованных моделей на базе архитектуры KAN

2.1 Подход с использованием регуляризации

2.2 Подход с изменением архитектуры

2.3 Подход с воспроизведением опыта

Глава 3. Применение усовершенствованных моделей в задачах непрерывного обучения

CUB-200-2011	
Объект выборки	RGB изображение
Количество классов	200
Количество признаков	2,048
Размер обучающей выборки	5,994
Размер тестовой выборки	5,794
Тренировочные объекты/класс	29-30
Тестовые объекты/класс	11-30

Таблица 1: Описание используемого набора данных

В качестве набора данных используется CUB-200-2011 (Таблица 1), содержащий в себе привычное для прикладных задач количество объектов и классов. Поскольку основная цель исследования - оценка эффективности противодействия моделей катастрофическому забыванию, а не сравнение качества векторных представлений объектов обучающей выборки, в качестве входных признаков используются векторные представления, полученные из предпоследнего слоя предобученной модели ResNet-50.

Согласно общепринятым рекомендациям, проводится несколько экспериментов:

1. Обучение с перестановкой признаков.
2. Инкрементальное обучение классам.

Первый эксперимент оценивает способность модели сохранять несколько представлений одного и того же набора данных, обучаясь на них последовательно. Второй эксперимент направлен на изучение способности модели обучаться новым классам данных, не забывая при этом ранее изученные классы.

3.1 Обучение с перестановкой признаков

3.2 Инкрементальное обучение классам

Глава 4. Анализ экспериментов

Выводы

Заключение

Список литературы

1. A Comprehensive Survey of Continual Learning: Theory, Method and Application / L. Wang [и др.] // arXiv preprint arXiv:2302.00487. — 2024. — DOI: 10.48550/arXiv.2302.00487. — arXiv: 2302.00487. — URL: <https://arxiv.org/abs/2302.00487> ; Accepted (concise version) in IEEE TPAMI.
2. *Chen Z., Liu B.* Lifelong Machine Learning. — Cham : Springer, 2017. — (Synthesis Lectures on Artificial Intelligence and Machine Learning). — ISBN 978-3-031-01575-5. — DOI: 10.1007/978-3-031-01575-5.
3. *Cheng Y.* Convergence and Ordering of Kohonen's Batch Map // Neural Computation. — 1997. — Т. 9, № 8. — С. 1667—1676. — DOI: 10.1162/neco.1997.9.8.1667. — URL: <https://doi.org/10.1162/neco.1997.9.8.1667> (дата обр. 06.05.2025).
4. Continual Lifelong Learning with Neural Networks: A Review / G. I. Parisi [и др.]. — 2018. — DOI: 10.48550/arXiv.1802.07569. — arXiv: 1802.07569 [cs.LG]. — URL: <https://arxiv.org/abs/1802.07569> (дата обр. 06.05.2025) ; version 4, revised 2019-02-11.
5. *Coop R., Mishtal A., Arel I.* Ensemble Learning in Fixed Expansion Layer Networks for Mitigating Catastrophic Forgetting // IEEE Transactions on Neural Networks and Learning Systems. — 2013. — Т. 24, № 10. — С. 1623—1634. — DOI: 10.1109/TNNLS.2013.2264952.
6. Experience Replay for Continual Learning / D. Rolnick [и др.] // Advances in Neural Information Processing Systems. Т. 32 / под ред. Н. М. Wallach [и др.]. — Curran Associates, Inc., 2019. — С. 348—358. — (Proceedings of Neural Information Processing Systems). — DOI: 10.48550/arXiv.1811.11682. — URL: <https://papers.nips.cc/paper/8327-experience-replay-for-continual-learning> (дата обр. 13.05.2025).
7. *Gepperth A., Karaoguz C.* A Bio-Inspired Incremental Learning Architecture for Applied Perceptual Problems // Cognitive Computation. — 2016. — Т. 8, № 5. — С. 924—934. — DOI: 10.1007/s12559-016-9389-5.

8. *Hinton G., Vinyals O., Dean J.* Distilling the Knowledge in a Neural Network. — 2015. — arXiv: 1503.02531 [stat.ML]. — URL: <https://arxiv.org/abs/1503.02531> (дата обр. 11.05.2025) ; version 1.
9. KAN 2.0: Kolmogorov-Arnold Networks Meet Science / Z. Liu [и др.]. — 2024. — DOI: 10.48550/arXiv.2408.10205. — arXiv: 2408.10205 [cs.LG]. — URL: <https://arxiv.org/abs/2408.10205> (дата обр. 05.05.2025) ; version 1.
10. KAN: Kolmogorov-Arnold Networks / Z. Liu [и др.]. — 2024. — DOI: 10.48550/arXiv.2404.19756. — arXiv: 2404.19756 [cs.LG]. — URL: <https://arxiv.org/abs/2404.19756> (дата обр. 02.05.2025) ; Accepted at ICLR 2025, version 5 (2025-02-09).
11. Kolmogorov-Arnold Networks Still Catastrophically Forget but Differently from MLP / A. Lee [и др.] // Proceedings of the AAAI Conference on Artificial Intelligence. Т. 39. — 2025. — С. 18053—18061. — DOI: 10.1609/aaai.v39i17.33986. — URL: <https://ojs.aaai.org/index.php/AAAI/article/view/33986> ; Technical Track on Machine Learning III.
12. *Kumar A., Agarwal S., Hemanth D. J.* A Methodology-Oriented Study of Catastrophic Forgetting in Incremental Deep Neural Networks. — 2024. — DOI: 10.48550/arXiv.2405.08015. — arXiv: 2405.08015 [cs.LG]. — URL: <https://arxiv.org/abs/2405.08015> (дата обр. 10.05.2025) ; version 1.
13. Learn++: An Incremental Learning Algorithm for Supervised Neural Networks / R. Polikar [и др.] // IEEE Transactions on Systems, Man and Cybernetics, Part C: Applications and Reviews. — 2001. — Т. 31, № 4. — С. 497—508. — DOI: 10.1109/5326.983933. — URL: <https://doi.org/10.1109/5326.983933> (дата обр. 13.05.2025).
14. *Li Z., Hoiem D.* Learning without Forgetting // Computer Vision - 14th European Conference on Computer Vision, ECCV 2016, Proceedings. Т. 9908 / под ред. B. Leibe [и др.]. — Cham : Springer, 2016. — С. 614—629. — (Lecture Notes in Computer Science). — DOI: 10.1007/978-3-

- 319-46493-0_37. — URL: https://doi.org/10.1007/978-3-319-46493-0_37 (дата обр. 11.05.2025).
15. Life-long Learning Based on Dynamic Combination Model / B. Ren [и др.] // *Applied Soft Computing*. — 2017. — Т. 56. — С. 398—404. — DOI: 10.1016/j.asoc.2017.03.005. — URL: <https://doi.org/10.1016/j.asoc.2017.03.005> (дата обр. 13.05.2025).
 16. *Liu Z.* PyKAN: Kolmogorov-Arnold Networks. — 2024. — URL: <https://github.com/KindXiaoming/pykan> (дата обр. 06.05.2025). GitHub repository.
 17. *Machine Learning for Data Streams: with Practical Examples in MOA / A. Bifet [и др.].* — Cambridge, MA : MIT Press, 2018. — (Adaptive Computation and Machine Learning). — ISBN 978-0262037792. — DOI: 10.7551/mitpress/10654.001.0001. — URL: <https://moa.cms.waikato.ac.nz/book/> (дата обр. 06.05.2025) ; 1st edition.
 18. Measuring Catastrophic Forgetting in Neural Networks / R. Kemker [и др.]. — 2017. — DOI: 10.48550/arXiv.1708.02072. — arXiv: 1708.02072 [cs.AI]. — URL: <https://arxiv.org/abs/1708.02072> (дата обр. 02.05.2025) ; To appear in AAAI 2018.
 19. Memory Aware Synapses: Learning what (not) to forget / R. Aljundi [и др.] // *Proceedings of the European Conference on Computer Vision (ECCV)*. — 2018. — URL: <https://arxiv.org/abs/1711.09601> (дата обр. 11.05.2025).
 20. Overcoming Catastrophic Forgetting in Neural Networks / J. Kirkpatrick [и др.] // *Proceedings of the National Academy of Sciences*. — 2017. — Т. 114, № 13. — С. 3521—3526. — DOI: 10.1073/pnas.1611835114.
 21. PathNet: Evolution Channels Gradient Descent in Super Neural Networks / C. Fernando [и др.]. — 2017. — DOI: 10.48550/arXiv.1701.08734. — arXiv: 1701.08734 [cs.NE]. — URL: <https://arxiv.org/abs/1701.08734> (дата обр. 02.05.2025) ; version 3.

22. Progress & Compress: A Scalable Framework for Continual Learning / J. Schwarz [и др.] // Proceedings of the 35th International Conference on Machine Learning. — 2018. — С. 4528—4537. — URL: <https://proceedings.mlr.press/v80/schwarz18a.html> (дата обр. 06.05.2025).
23. Progressive Neural Networks / A. A. Rusu [и др.]. — 2016. — DOI: 10.48550/arXiv.1606.04671. — arXiv: 1606.04671 [cs.LG]. — URL: <https://arxiv.org/abs/1606.04671> (дата обр. 13.05.2025) ; version 4.
24. Subspace Distillation for Continual Learning / K. Roy [и др.] // Neural Networks. — 2023. — Т. 167. — С. 65—79. — DOI: 10.1016/j.neunet.2023.07.047. — URL: <https://doi.org/10.1016/j.neunet.2023.07.047> (дата обр. 11.05.2025).
25. *Tretyakov D.* SPBU Bachelor Thesis. — 2025. — URL: <https://github.com/trxxxxkov/spbu-bachelor-thesis> (дата обр. 02.05.2025). GitHub repository.
26. *Yu R., Yu W., Wang X.* KAN or MLP: A Fairer Comparison. — 2024. — DOI: 10.48550/arXiv.2407.16674. — arXiv: 2407.16674 [cs.LG]. — URL: <https://arxiv.org/abs/2407.16674> (дата обр. 05.05.2025) ; version 2.
27. *Zenke F., Poole B., Ganguli S.* Continual Learning Through Synaptic Intelligence // Proceedings of the 34th International Conference on Machine Learning. — 2017. — С. 3987—3995. — URL: <https://proceedings.mlr.press/v70/zenke17a.html> (дата обр. 11.05.2025).

Приложение