

Санкт–Петербургский государственный университет

ТРЕТЬЯКОВ Даниил Александрович

Выпускная квалификационная работа

Исследование эффективности непрерывного обучения с использованием сетей Колмогорова-Арнольда в задаче распознавания образов

Уровень образования: бакалавриат

Направление 01.03.02 «Прикладная математика и информатика»

Основная образовательная программа СВ.5005.2021 «Прикладная математика, фундаментальная информатика и программирование»

Научный руководитель:

профессор кафедры компьютерного моделирования и многопроцессорных систем, д.т.н. Дегтярев Александр Борисович

Рецензент:

доцент кафедры компьютерного моделирования и многопроцессорных систем, к.ф.-м.н. Корхов Владимир Владиславович

Санкт-Петербург

2025 г.

Содержание

Введение	4
Постановка задачи	8
Обзор литературы	11
Глава 1. Анализ существующих подходов к преодолению катастрофического забывания	13
1.1. Подход с использованием ансамблирования	13
1.2. Подход с использованием регуляризации	13
1.3. Подход с использованием разреженного кодирования представлений	13
1.4. Подход с воспроизведением опыта	13
Глава 2. Построение усовершенствованных моделей на базе архитектуры KAN	14
2.1. Использование оригинальной архитектуры KAN	14
2.2. Подход с использованием ансамблирования	14
2.3. Подход с использованием регуляризации	14
2.4. Подход с использованием разреженного кодирования представлений	14
2.5. Подход с производением опыта	14
Глава 3. Применение усовершенствованных моделей в задачах непрерывного обучения	15
3.1. Обучение с перестановкой признаков	15
3.2. Инкрементальное обучение классам	15
Глава 4. Анализ экспериментов	16
4.1. Сравнение усовершенствованных моделей на базе архитектуры KAN	16
4.2. Сравнение эффективности подходов применительно к архитектурам KAN и MLP	16
Выводы	17
Заключение	18

Список литературы	19
Приложение	20

Введение

В последние десятилетия нейронные сети стали неотъемлемой частью современных интеллектуальных систем. Их способность аппроксимировать сложные зависимости и выявлять скрытые паттерны в больших объемах данных делает их незаменимыми инструментами в сложных исследовательских и прикладных задачах. Именно нейронные сети сделали возможным появление алгоритмов, превосходящих человеческие возможности в областях, где люди традиционно считались непревзойденными, например — в распознавании изображений и речи, играх и стратегиях, медицинской диагностике.

Однако в отличие от человека, для нейронной сети, после того как она была обучена выполнению определенной задачи, например, классификации деревьев, обучение дополнительной задаче, например, классификации птиц, оказывается затруднительным. Это связано с тем, что при добавлении новой задачи типичная нейронная сеть склонна "забывать" предыдущую. В связи с этим, одним из актуальных направлений в развитии нейронных сетей является непрерывное обучение - подход, при котором модель способна обучаться и адаптироваться на протяжении всего срока её эксплуатации с целью поддержания своей производительности в условиях изменяющихся данных и окружающей среды, без необходимости полного переобучения. Потребность в подобных моделях особенно сильна в рекламной индустрии, финансовой аналитике, робототехнике и кибербезопасности.

Как правило, в исследованиях, посвященных методам преодоления катастрофического забывания, рассматривается одна и та же архитектура - многослойный перцептрон (Multi-Layer Perceptron, MLP). Это связано с тем, что MLP - одна из самых простых и универсальных архитектур нейронных сетей - обладает основополагающим свойством: способностью выступать в роли универсального аппроксиматора. Она является неотъемлемым компонентом большинства современных архитектур, таких как CNN, RNN и трансформеры, поэтому методы, решающие проблему катастрофического забывания в MLP, одновременно являются решением и для многих других нейронных сетей.

Несмотря на то, что в борьбе с катастрофическим забыванием в много-

слои перцептроне были достигнуты определенные успехи, в последнее время растёт интерес к многообещающей альтернативе, также подходящей на роль универсального аппроксиматора - нейронной сети Колмогорова-Арнольда (Kolmogorov-Arnold Network, KAN). Ключевые различия между архитектурами MLP и KAN представлены на рисунке 1: в то время как в многослойном перцептроне функции активации фиксированы и применяются к выходам нейронов, в KAN функции активации применяются на месте линейных весов в MLP, являются обучаемыми и могут быть параметризованы, например, с помощью базисных сплайнов. Теоретической основой для MLP служит теорема Цыбенко (также известная как Универсальная теорема аппроксимации), а в случае KAN источником вдохновения стала теорема о представлении Колмогорова—Арнольда.





Model	Multi-Layer Perceptron (MLP)	Kolmogorov-Arnold Network (KAN)
Theorem	Universal Approximation Theorem	Kolmogorov-Arnold Representation Theorem
Formula (Shallow)	$f(\mathbf{x}) \approx \sum_{i=1}^{N(e)} a_i \sigma(\mathbf{w}_i \cdot \mathbf{x} + b_i)$	$f(\mathbf{x}) = \sum_{q=1}^{2n+1} \Phi_q \left(\sum_{p=1}^n \phi_{q,p}(x_p) \right)$
Model (Shallow)	(a)  fixed activation functions on nodes learnable weights on edges	(b)  learnable activation functions on edges sum operation on nodes
Formula (Deep)	$\text{MLP}(\mathbf{x}) = (\mathbf{W}_3 \circ \sigma_2 \circ \mathbf{W}_2 \circ \sigma_1 \circ \mathbf{W}_1)(\mathbf{x})$	$\text{KAN}(\mathbf{x}) = (\Phi_3 \circ \Phi_2 \circ \Phi_1)(\mathbf{x})$
Model (Deep)	(c)  MLP(x) $\mathbf{W}_3$ σ_2 $\mathbf{W}_2$ σ_1 $\mathbf{W}_1$ nonlinear, fixed linear, learnable $\mathbf{x}$	(d)  KAN(x) Φ_3 Φ_2 Φ_1 nonlinear, learnable $\mathbf{x}$

Рис. 1: Сравнение MLP и KAN. Взято из [5], лицензия: CC BY 4.0.

Главная причина, по которой KAN представляет интерес с точки зрения применения в условиях непрерывного обучения, заключается в возможности параметризации функции активации таким образом, чтобы изменение параметров в одной области пространства не влияло на другие области. Это возможно, например, при использовании B-сплайнов, обладающих локальной поддержкой. Поскольку обучение на новых данных будет затрагивать лишь

несколько соседних параметров, информация, сохранённая в остальных параметрах, остается нетронутой. В MLP, напротив, даже отдельные изменения могут повлиять на информацию, хранящуюся в отдалённых друг от друга параметрах.

Для демонстрации преимуществ, связанных с локальной поддержкой функции активации, предлагается рассмотреть простейшую задачу одномерной регрессии, детали которой приведены на рисунке 2: обучение состоит из 5 тренировочных сессий, в каждой из которых используются исключительно объекты из соответствующей части набора данных, также разделённого на 5 частей. Можно заметить, что в данной задаче KAN изменяет только те параметры, которые отвечают за аппроксимацию зависимости в данных текущей тренировочной сессии, в то время как MLP оказывается не способен сохранить информацию, полученную в течении предыдущих тренировочных сессий.




Рис. 2: Простейшая задача непрерывного обучения. Взято из [5], лицензия: CC BY 4.0.

Рассмотренная задача является лишь упрощённым примером, в котором особенности архитектуры KAN позволили существенно повлиять на эффективность непрерывного обучения. В прикладных задачах размерность параметрического пространства нейронных сетей, как правило, значительно выше, и сохранение свойства локальности изменений параметров оказывается под вопросом. Поскольку тестирование только оригинальной архитектуры KAN не позволяет в полной мере оценить её перспективы в сочетании с совре-

менными методами преодоления катастрофического забывания, возникает необходимость адаптации методов, разработанных для многослойного перцептрона, для использования в сетях Колмогорова-Арнольда. Данная работа посвящена адаптации этих методов, а также исследованию эффективности полученных моделей в условиях непрерывного обучения на задаче распознавания образов с использованием набора данных, обладающего свойствами, характерными для прикладных задач.

Полный исходный код, а также графические материалы, использованные в работе, размещены в публичном репозитории на GitHub по ссылке: [9]

Постановка задачи

Рассматривается процесс непрерывного обучения нейронных сетей на базе архитектур KAN и MLP в задаче распознавания образов. Набор данных D состоит из размеченных объектов, разбитых на T частей, соответствующих тренировочным сессиям, то есть $D = \{B_t\}_{t=1}^T$. Каждая тренировочная сессия B_t состоит из N_t объектов (N_t может изменяться между сессиями). Таким образом, $B_t = \{(\mathbf{x}_i, y_i)\}_{i=1}^{N_t}$, где $\mathbf{x}_i \in \mathbb{R}^d$, $y_i \in \mathbb{N}$.

Обучение моделей происходит исключительно на объектах текущей тренировочной сессии, то есть в момент времени t модель может использовать лишь данные из B_t . Допускается использование моделями дополнительной памяти для хранения объектов из предыдущих тренировочных сессий, но это должно быть отражено в отчёте.

Согласно общепринятым рекомендациям, проводится несколько экспериментов:

1. Обучение с перестановкой признаков.
2. Инкрементальное обучение классам.

Первый эксперимент оценивает способность модели сохранять несколько представлений одного и того же набора данных, обучаясь на них последовательно. Второй эксперимент направлен на изучение способности модели обучаться новым классам данных, не забывая при этом ранее изученные классы.

CUB-200-2011	
Объект выборки	RGB изображение
Количество классов	200
Количество признаков	2,048
Размер обучающей выборки	5,994
Размер тестовой выборки	5,794
Тренировочные объекты/класс	29-30
Тестовые объекты/класс	11-30

Таблица 1: Описание используемого набора данных

В качестве набора данных используется CUB-200-2011 (Таблица 1), содержащий в себе привычное для прикладных задач количество объектов и классов. Поскольку основная цель исследования - оценка эффективности противодействия моделей катастрофическому забыванию, а не сравнение качества векторных представлений объектов обучающей выборки, в качестве входных признаков используются векторные представления, полученные из предпоследнего слоя предобученной модели ResNet-50.

Для оценки способности моделей сохранять знания из предыдущих обучающих сессий в процессе непрерывного обучения выбраны следующие метрики:

$$\Omega_{new} = \frac{1}{T-1} \sum_{i=2}^T \frac{\alpha_{new,i}}{\alpha_{ideal}}$$

$$\Omega_{base} = \frac{1}{T-1} \sum_{i=2}^T \frac{\alpha_{base,i}}{\alpha_{ideal}}$$

$$\Omega_{all} = \frac{1}{T-1} \sum_{i=2}^T \frac{\alpha_{all,i}}{\alpha_{ideal}}$$

где $\alpha_{new,i}$ - значение метрики ассигасу на тестовой выборке i -ой тренировочной сессии сразу после обучения модели на ней, $\alpha_{base,i}$ - значение метрики ассигасу на тестовой выборке первой тренировочной сессии сразу после обучения модели в i -ой тренировочной сессии, $\alpha_{all,i}$ - значение метрики ассигасу на элементах тестовых выборок всех увиденных тренировочных сессий, α_{ideal} - значение метрики ассигасу на тестовой выборке первой тренировочной сессии при обучении MLP на всём наборе данных. Таким образом, Ω_{new} измеряет способность модели использовать только что приобретенные знания, Ω_{base} измеряет способность модели удерживать в памяти знания, полученные в первой тренировочной сессии, а Ω_{all} оценивает общую эффективность использования накопленных данных.

Цель и задачи исследования

Целью данной работы является исследование возможности применения архитектуры KAN для решения задачи распознавания образов в условиях

непрерывного обучения посредством разработки и анализа усовершенствованных моделей, адаптирующих основные подходы к преодолению катастрофического забывания в MLP для сетей Колмогорова-Арнольда.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Изучить существующие методы борьбы с катастрофическим забыванием в MLP.
2. Разработать усовершенствованные модели KAN, адаптировав методы преодоления катастрофического забывания для этой архитектуры.
3. Провести эксперименты с усовершенствованными моделями для задачи распознавания образов в условиях непрерывного обучения.
4. Сравнить результаты усовершенствованных моделей между собой и с соответствующими моделями на базе архитектуры MLP.
5. Проанализировать результаты экспериментов и оценить перспективы применения сетей Колмогорова-Арнольда в задачах непрерывного обучения.

Обзор литературы

Основу данной работы составила публикация [5]. В ней описана архитектура нейронных сетей Колмогорова-Арнольда и даны математические обоснования её эффективности, а также в нескольких научных и прикладных задачах продемонстрированы её преимущества перед традиционным многослойным перцептроном. Помимо прочего, в ней сформулировано требовавшее дальнейших исследований предположение о большом потенциале использования KAN в непрерывном обучении.

Несмотря на значительное количество научных публикаций, монографий по теме непрерывного обучения немного. Изучение материала строилось на основе [2]. Эта работа предоставляет всесторонний обзор теоретических и практических аспектов непрерывного обучения, освещая в том числе и передовые на момент написания книги методы.

В процессе адаптации методов борьбы с катастрофическим забыванием использовались замечания, сформулированные в исследовании [6]. Вследствие обоснованной критики исследования катастрофического забывания на малых наборах данных (например, MNIST), было принято решение об использовании одного из предложенных в этой статье наборов данных, обладающего свойствами, схожими с таковыми в обыкновенных прикладных задачах. Также была перенята предложенная в статье система классификации с разделением подходов для преодоления катастрофического забывания на использующие ансамблирование, регуляризацию, разреженное кодирование и воспроизведение опыта.

Подробная информация о передовых методах в каждой из этих категорий была получена из соответствующих статей: [3; 4; 7; 8]. Из них же были получены детали реализации соответствующих архитектур, что позволило воспроизвести результаты статей и послужило источником вдохновения для создания собственных усовершенствованных моделей на базе KAN.

Помимо исследований по теме непрерывного обучения, посвященным внесению архитектурных изменений в нейронные сети, была использована информация из [1] о влиянии выбора функций активации и классических приемов регуляризации на эффект от катастрофического забывания. Полу-

ченные в этой работе выводы использовались скорее с обратной относительно всего остального целью - не допустить воздействия на проводимое исследование посторонних факторов или же уровнять их воздействие путем подбора таких параметров, которые, согласно выводам данной публикации, не дадут преимуществ какой-либо из архитектур.

Глава 1. Анализ существующих подходов к преодолению катастрофического забывания

Поскольку явление, приводящее к потере моделью ранее выученной информации при дообучении, получившее название катастрофического забывания, является основным вызовом в области непрерывного обучения, для борьбы с ним разработаны многочисленные методы, которые можно разделить на четыре основных подхода:

- С использованием ансамблирования: предполагается построение для каждой новой задачи специализирующейся на ней модели с последующим объединением всех моделей в единый ансамбль.
- С использованием регуляризации: в функцию потерь добавляются регуляризирующие члены, призванные сохранить значения важных параметров, связанных с предыдущими задачами.
- С использованием разреженного кодирования представлений: разреженность в представлениях подразумевает, что только небольшая часть нейронов активируется для обработки конкретного входного сигнала, что снижает вероятность перезаписи информации, хранящейся в весах нейронной сети.
- С воспроизведением опыта: основаны на идее периодического повторения данных из предыдущих задач во время обучения на новых задачах. Это позволяет модели "освежать" свои знания о старых задачах и предотвращать их забывание.

1.1 Подход с использованием ансамблирования

1.2 Подход с использованием регуляризации

1.3 Подход с использованием разреженного кодирования представлений

1.4 Подход с воспроизведением опыта

Глава 2. Построение усовершенствованных моделей на базе архитектуры KAN

Здесь будут описаны изменения, внесённые в архитектуру KAN в соответствии с идеями каждого из рассмотренных в предыдущей главе подходов, а также описаны параметры и гиперпараметры, использованные в каждой из полученных моделей, так, чтобы стало возможным полное воспроизведение процесса усовершенствования.

- 2.1 Использование оригинальной архитектуры KAN**
- 2.2 Подход с использованием ансамблирования**
- 2.3 Подход с использованием регуляризации**
- 2.4 Подход с использованием разреженного кодирования представлений**
- 2.5 Подход с производением опыта**

Глава 3. Применение усовершенствованных моделей в задачах непрерывного обучения

Здесь будут описаны детали эксперимента с перестановкой признаков (используется для оценки способности модели справляться с катастрофическим забыванием в условиях, когда данные изменяются, но сохраняют ту же структуру) и обучения с постепенным добавлением новых классов, а также приведены таблицы с результатами применения в них каждой из усовершенствованных моделей, полученных в предыдущей главе

3.1 Обучение с перестановкой признаков

3.2 Инкрементальное обучение классам

Глава 4. Анализ экспериментов

Здесь будет произведён анализ результатов полученных моделей как между собой (как представителей одной архитектуры), так и с результатами соответствующих аналогов (полученных с использованием тех же подходов) на базе архитектуры MLP.

4.1 Сравнение усовершенствованных моделей на базе архитектуры KAN

4.2 Сравнение эффективности подходов применительно к архитектурам KAN и MLP

Выводы

Заключение

Список литературы

1. An Empirical Investigation of Catastrophic Forgetting in Gradient-Based Neural Networks / I. J. Goodfellow [и др.]. — 2013. — arXiv: 1312.6211 [stat.ML]. — URL: <https://arxiv.org/abs/1312.6211> (дата обр. 02.05.2025); version 3, revised 2015-03-04.
2. *Chen Z., Liu B.* Lifelong Machine Learning. — Cham : Springer, 2017. — (Synthesis Lectures on Artificial Intelligence and Machine Learning). — ISBN 978-3-031-01575-5. — DOI: 10.1007/978-3-031-01575-5.
3. *Coop R., Mishtal A., Arel I.* Ensemble Learning in Fixed Expansion Layer Networks for Mitigating Catastrophic Forgetting // IEEE Transactions on Neural Networks and Learning Systems. — 2013. — Т. 24, № 10. — С. 1623—1634. — DOI: 10.1109/TNNLS.2013.2264952.
4. *Gepperth A., Karaoguz C.* A Bio-Inspired Incremental Learning Architecture for Applied Perceptual Problems // Cognitive Computation. — 2016. — Т. 8, № 5. — С. 924—934. — DOI: 10.1007/s12559-016-9389-5.
5. KAN: Kolmogorov-Arnold Networks / Z. Liu [и др.]. — 2024. — arXiv: 2404.19756 [cs.LG]. — URL: <https://arxiv.org/abs/2404.19756> (дата обр. 02.05.2025); Accepted at ICLR 2025, version 5 (2025-02-09).
6. Measuring Catastrophic Forgetting in Neural Networks / R. Kemker [и др.]. — 2017. — arXiv: 1708.02072 [cs.AI]. — URL: <https://arxiv.org/abs/1708.02072> (дата обр. 02.05.2025); To appear in AAAI 2018.
7. Overcoming Catastrophic Forgetting in Neural Networks / J. Kirkpatrick [и др.] // Proceedings of the National Academy of Sciences. — 2017. — Т. 114, № 13. — С. 3521—3526. — DOI: 10.1073/pnas.1611835114.
8. PathNet: Evolution Channels Gradient Descent in Super Neural Networks / C. Fernando [и др.]. — 2017. — arXiv: 1701.08734 [cs.NE]. — URL: <https://arxiv.org/abs/1701.08734> (дата обр. 02.05.2025); version 3.
9. *Tretyakov D.* SPBU Bachelor Thesis. — 2025. — URL: <https://github.com/trxxxxkov/spbu-bachelor-thesis> (дата обр. 02.05.2025). GitHub repository.

Приложение