

Санкт–Петербургский государственный университет

ТРЕТЬЯКОВ Даниил Александрович

Выпускная квалификационная работа

Исследование эффективности непрерывного обучения с использованием сетей Колмогорова-Арнольда в задаче распознавания образов

Уровень образования: бакалавриат

Направление 01.03.02 «Прикладная математика и информатика»

Основная образовательная программа СВ.5005.2021 «Прикладная математика, фундаментальная информатика и программирование»

Научный руководитель:

профессор кафедры компьютерного моделирования и многопроцессорных систем, д.т.н. Дегтярев Александр Борисович

Рецензент:

TODO: обновить инфу

Санкт-Петербург

2025 г.

Содержание

Введение

В последние десятилетия нейронные сети стали неотъемлемой частью современных интеллектуальных систем. Их способность аппроксимировать сложные зависимости и выявлять скрытые паттерны в больших объемах данных делает их незаменимыми инструментами в сложных исследовательских и прикладных задачах. Именно они сделали возможным появление алгоритмов, превосходящих человеческие возможности в областях, где люди традиционно считались непревзойденными, например — в распознавании изображений и речи, играх и стратегиях, медицинской диагностике.

Однако после того, как нейронная сеть была обучена выполнению определенной задачи, например, классификации деревьев, её обучение дополнительной задаче, например, классификации птиц, оказывается затруднительным. Это связано с тем, что при добавлении новой задачи типичная нейронная сеть склонна "забывать" предыдущую. В связи с этим, одним из актуальных направлений в развитии нейронных сетей является непрерывное обучение - подход, при котором модель обучается и адаптируется на протяжении всего времени её эксплуатации с целью поддержания своей производительности в условиях изменяющихся данных и окружающей среды, без необходимости полного переобучения. Потребность в подобных моделях особенно сильна в рекламной индустрии, финансовой аналитике, робототехнике и кибербезопасности.

Поскольку феномен катастрофического забывания является основным вызовом в области непрерывного обучения, для борьбы с ним разработаны подходы, которые можно разделить на четыре категории:

- С использованием ансамблирования: предполагается построение для каждой новой задачи специализирующейся на ней модели с последующим объединением всех моделей в единый ансамбль.
- С использованием регуляризации: в функцию потерь добавляются регуляризирующие члены, призванные сохранить важные параметры, связанные с предыдущими задачами.

- С использованием разреженного кодирования представлений: разреженность в представлениях подразумевает, что только небольшая часть нейронов активируется для обработки конкретного входного сигнала, что снижает вероятность "перезаписи" информации.
- С воспроизведением опыта: основаны на идее периодического повторения данных из предыдущих задач во время обучения на новых задачах. Это позволяет модели "освежать" свои знания о старых задачах и предотвращать их забывание.

Как правило, в исследованиях, посвященных методам преодоления катастрофического забывания, чаще всего рассматривается одна и та же архитектура - многослойный перцептрон (Multi-Layer Perceptron, MLP). Это связано с тем, что MLP - одна из самых простых и универсальных архитектур нейронных сетей - обладает основополагающим свойством: способностью выступать в роли универсального аппроксиматора, что позволяет эффективно обрабатывать высокоуровневые признаки. Благодаря этому MLP становится важным компонентом многих современных моделей, таких как CNN, RNN и трансформеры.

Несмотря на определённые успехи в борьбе с катастрофическим забыванием в многослойных перцептронах, существует альтернативная архитектура, подходящая для использования в качестве универсального аппроксиматора — сети Колмогорова-Арнольда (Kolmogorov-Arnold Networks, KAN). В отличие от многослойного перцептрона, где функции активации фиксированы и применяются к выходам нейронов, в KAN функции активации применяются на месте линейных весов в MLP и являются обучаемыми. Они могут быть параметризованы, например, с помощью базисных сплайнов. Такая архитектура основывается на теореме Колмогорова-Арнольда, которая утверждает, что любая непрерывная функция может быть представлена в виде суперпозиции унарных функций и бинарной операции сложения.

Теоретическая основа KAN, в частности, свойство локальности базисных сплайнов, позволяет более эффективно контролировать влияние отдельных параметров на итоговое представление, что, в свою очередь, может способствовать снижению проявлений катастрофического забывания. Поэтому

ождается, что подходы, разработанные для борьбы с этим феноменом в MLP, продемонстрируют лучшие результаты при их применении в KAN.

Данная работа посвящена разработке и адаптации методов преодоления катастрофического забывания для архитектуры сетей Колмогорова-Арнольда, а также исследованию эффективности полученных моделей в задачах распознавания образов. В рамках исследования планируется проведение сравнительного анализа усовершенствованных моделей KAN и соответствующих моделей на базе MLP, что позволит оценить потенциал новой архитектуры в контексте непрерывного обучения.

Постановка задачи

Рассматривается процесс непрерывного обучения нейронных сетей на базе архитектур KAN и MLP в задаче распознавания образов. Набор данных D состоит из размеченных объектов, разбитых на T частей, соответствующих тренировочным сессиям, то есть $D = \{B_t\}_{t=1}^T$. Каждая тренировочная сессия B_t состоит из N_t объектов (N_t может изменяться между сессиями). Таким образом, $B_t = \{(\mathbf{x}_i, y_i)\}_{i=1}^{N_t}$, где $\mathbf{x}_i \in \mathbb{R}^d$, $y_i \in \mathbb{N}$.

Обучение моделей происходит исключительно на объектах текущей тренировочной сессии, то есть в момент времени t модель может использовать лишь данные из B_t . Использование моделями дополнительной памяти для хранения объектов из предыдущих тренировочных сессий допускается.

Согласно общепринятым рекомендациям, проводится несколько экспериментов:

1. Обучение с перестановкой данных.
2. Инкрементальное обучение классам.

Первый эксперимент оценивает способность модели сохранять несколько представлений одного и того же набора данных, обучаясь на них последовательно. Второй эксперимент направлен на изучение способности модели обучаться новым классам данных, не забывая при этом ранее изученные классы.

CUB-200-2011	
Объект выборки	RGB изображение
Количество классов	200
Количество признаков	2,048
Размер обучающей выборки	5,994
Размер тестовой выборки	5,794
Тренировочные объекты/класс	29-30
Тестовые объекты/класс	11-30

Таблица 1: Описание используемого набора данных

В качестве набора данных используется CUB-200-2011, содержащий в себе типичное для прикладных задач количество объектов и классов. Посколь-

ку основная цель исследования - оценка эффективности противодействия моделей катастрофическому забыванию, а не сравнение качества векторных представлений объектов обучающей выборки, в качестве входных признаков будут использоваться векторные представления, полученные из предпоследнего слоя предобученной модели ResNet-50.

Для оценки способности моделей сохранять знания из предыдущих обучающих сессий в процессе непрерывного обучения будут использоваться следующие метрики:

$$\Omega_{new} = \frac{1}{T-1} \sum_{i=2}^T \frac{\alpha_{new,i}}{\alpha_{ideal}}$$

$$\Omega_{base} = \frac{1}{T-1} \sum_{i=2}^T \frac{\alpha_{base,i}}{\alpha_{ideal}}$$

$$\Omega_{all} = \frac{1}{T-1} \sum_{i=2}^T \frac{\alpha_{all,i}}{\alpha_{ideal}}$$

где $\alpha_{new,i}$ - значение метрики ассигасу на тестовой выборке i -ой тренировочной сессии сразу после обучения модели на ней, $\alpha_{base,i}$ - значение метрики ассигасу на тестовой выборке первой тренировочной сессии сразу после обучения модели в i -ой тренировочной сессии, $\alpha_{all,i}$ - значение метрики ассигасу на элементах тестовых выборок всех увиденных тренировочных сессий, α_{ideal} - значение метрики ассигасу на тестовой выборке первой тренировочной сессии при обучении MLP в оффлайн-режиме. Таким образом, Ω_{new} измеряет способность модели использовать только что приобретенные знания, Ω_{base} измеряет способность модели удерживать в памяти знания, полученные в первой тренировочной сессии, а Ω_{all} оценивает общую эффективность удержания старых знаний и использования новой информации.

Цель и задачи исследования

Целью данной работы является исследование возможности применения архитектуры KAN для решения задачи распознавания образов в условиях непрерывного обучения посредством разработки и анализа усовершенство-

ванных моделей, адаптирующих основные подходы к преодолению катастрофического забывания в MLP для сетей Колмогорова-Арнольда.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Изучить существующие методы борьбы с катастрофическим забыванием в MLP.
2. Разработать усовершенствованные модели KAN, адаптировав методы преодоления катастрофического забывания для этой архитектуры.
3. Провести эксперименты с усовершенствованными моделями для задачи распознавания образов в условиях непрерывного обучения.
4. Сравнить результаты усовершенствованных моделей между собой и с соответствующими моделями на базе архитектуры MLP.
5. Проанализировать результаты экспериментов и оценить перспективы применения сетей Колмогорова-Арнольда в задачах непрерывного обучения.

Обзор литературы

Глава 1. Анализ существующих подходов к преодолению катастрофического забывания

Здесь будут рассмотрены четыре основных подхода к изменению архитектуры MLP, используемых для смягчения влияния катастрофического забывания. Для каждого из подходов будут описаны представители, сравнение эффективности которых с аналогами на базе архитектуры KAN будет произведено в главе "анализ экспериментов".

1.1 Подход с использованием ансамблирования

1.2 Подход с использованием регуляризации

1.3 Подход с использованием разреженного кодирования представлений

1.4 Подход с воспроизведением опыта

Глава 2. Построение усовершенствованных моделей на базе архитектуры KAN

Здесь будут описаны изменения, внесённые в архитектуру KAN в соответствии с идеями каждого из рассмотренных в предыдущей главе подходов, а также описаны параметры и гиперпараметры, использованные в каждой из полученных моделей, так, чтобы стало возможным полное воспроизведение процесса усовершенствования.

2.1 Использование оригинальной архитектуры KAN

2.2 Подход с использованием ансамблирования

2.3 Подход с использованием регуляризации

2.4 Подход с использованием разреженного кодирования представлений

2.5 Подход с производением опыта

Глава 3. Применение усовершенствованных моделей в задачах непрерывного обучения

Здесь будут описаны детали эксперимента с перестановкой данных (используется для оценки способности модели справляться с катастрофическим забыванием в условиях, когда данные изменяются, но сохраняют ту же структуру) и обучения с постепенным добавлением новых классов, а также приведены таблицы с результатами применения в них каждой из усовершенствованных моделей, полученных в предыдущей главе

3.1 Обучение с перестановкой данных

3.2 Инкрементальное обучение классам

Глава 4. Анализ экспериментов

Здесь будет произведён анализ результатов полученных моделей как между собой (как представителей одной архитектуры), так и с результатами соответствующих аналогов (полученных с использованием тех же подходов) на базе архитектуры MLP.

4.1 Сравнение усовершенствованных моделей на базе архитектуры KAN

4.2 Сравнение эффективности подходов применительно к архитектурам KAN и MLP

Выводы

Заключение

Список литературы

Приложение