

Санкт–Петербургский государственный университет

ТРЕТЬЯКОВ Даниил Александрович

Выпускная квалификационная работа

Исследование эффективности непрерывного обучения с использованием сетей Колмогорова-Арнольда в задаче распознавания образов

Уровень образования: бакалавриат

Направление 01.03.02 «Прикладная математика и информатика»

Основная образовательная программа СВ.5005.2021 «Прикладная математика, фундаментальная информатика и программирование»

Научный руководитель:

профессор кафедры компьютерного моделирования и многопроцессорных систем, д.т.н. Дегтярев Александр Борисович

Рецензент:

TODO: обновить инфу

Санкт-Петербург

2025 г.

Содержание

Введение

В последние десятилетия нейронные сети стали неотъемлемой частью современных интеллектуальных систем. Их способность аппроксимировать сложные зависимости и выявлять скрытые паттерны в больших объемах данных делает их незаменимыми инструментами в сложных исследовательских и прикладных задачах. Именно они сделали возможным появление алгоритмов, превосходящих человеческие возможности в областях, где люди традиционно считались непревзойденными, например — в распознавании изображений и речи, играх и стратегиях, медицинской диагностике.

Однако после того, как нейронная сеть была обучена выполнению определенной задачи, например, классификации деревьев, её обучение дополнительной задаче, например, классификации птиц, оказывается затруднительным. Это связано с тем, что при добавлении новой задачи типичная нейронная сеть склонна "забывать" предыдущую. В связи с этим, одним из актуальных направлений в развитии нейронных сетей является непрерывное обучение - подход, при котором модель обучается и адаптируется на протяжении всего времени её эксплуатации с целью поддержания своей производительности в условиях изменяющихся данных и окружающей среды, без необходимости полного переобучения. Потребность в подобных моделях особенно сильна в рекламной индустрии, финансовой аналитике, робототехнике и кибербезопасности.

Поскольку феномен катастрофического забывания является основным вызовом в области непрерывного обучения, для борьбы с ним разработаны подходы, которые можно разделить на четыре категории:

1. С использованием ансамблирования: предполагается построение для каждой новой задачи специализирующейся на ней модели с последующим объединением всех моделей в единый ансамбль.
2. С использованием регуляризации: в функцию потерь добавляются регуляризирующие члены, призванные сохранить важные параметры, связанные с предыдущими задачами.

3. С использованием разреженного кодирования представлений: разреженность в представлениях подразумевает, что только небольшая часть нейронов активируется для обработки конкретного входного сигнала, что снижает вероятность "перезаписи" информации.
4. С воспроизведением опыта: основаны на идее периодического повторения данных из предыдущих задач во время обучения на новых задачах. Это позволяет модели "освежать" свои знания о старых задачах и предотвращать их забывание.

Как правило, в исследованиях, посвященных методам борьбы с катастрофическим забыванием, чаще всего рассматривается одна и та же архитектура - многослойный перцептрон (Multi-Layer Perceptron, MLP). Это связано с тем, что MLP - одна из самых простых и универсальных архитектур нейронных сетей - обладает основополагающим свойством: способностью выступать в роли универсального аппроксиматора, что позволяет эффективно обрабатывать высокоуровневые признаки. Благодаря этому MLP становится важным компонентом многих современных моделей, таких как CNN, RNN и трансформеры.

Несмотря на определённые успехи в борьбе с катастрофическим забыванием в многослойных перцептронах, существует альтернативная архитектура, подходящая для использования в качестве универсального аппроксиматора — сети Колмогорова-Арнольда (Kolmogorov-Arnold Networks, KAN). В отличие от MLP, где функции активации фиксированы и применяются к выходам нейронов, в KAN функции активации применяются на месте традиционных линейных весов и являются обучаемыми. Они могут быть параметризованы, например, с помощью базисных сплайнов. Такая архитектура основывается на теореме Колмогорова-Арнольда, которая утверждает, что любая непрерывная функция может быть представлена в виде суперпозиции унарных функций и бинарной операции сложения.

Теоретическая основа KAN, в частности, свойство локальности базисных сплайнов, позволяет более эффективно контролировать влияние отдельных параметров на итоговое представление, что, в свою очередь, может способствовать снижению проявлений катастрофического забывания. Поэтому

ождается, что подходы, разработанные для борьбы с этим феноменом в MLP, продемонстрируют лучшие результаты при их применении в KAN.

Данная работа посвящена разработке и адаптации методов преодоления катастрофического забывания для архитектуры сетей Колмогорова-Арнольда, а также исследованию эффективности полученных моделей в задачах распознавания образов. В рамках исследования планируется провести сравнительный анализ усовершенствованных моделей KAN и аналогичных моделей на базе MLP, что позволит лучше оценить потенциал новой архитектуры в контексте непрерывного обучения.

Постановка задачи

Рассматривается процесс непрерывного обучения нейронных сетей на базе архитектур KAN и MLP в задаче распознавания образов. Датасет D состоит из размеченных данных, разбитых на T частей, соответствующих обучающим сессиям, то есть $D = \{B_t\}_{t=1}^T$.

Цель и задачи исследования

Целью настоящего исследования является адаптация методов непрерывного обучения в задаче распознавания образов, разработанных для архитектуры MLP, к работе с сетями Колмогорова-Арнольда и последующий анализ полученных с помощью применения адаптированных методов новых архитектур как между собой (в рамках одной архитектуры KAN), так и с соответствующими аналогами на базе архитектуры MLP.

Для достижения поставленной цели необходимо решить следующие задачи:

- Провести обзор и анализ существующих методов преодоления катастрофического забывания, применяемых в многослойных перцептронах (MLP).
- Адаптировать выбранные методы непрерывного обучения для архитектуры сетей Колмогорова-Арнольда (KAN).
- Разработать усовершенствованные модели KAN с применением адаптированных методов непрерывного обучения.
- Организовать и провести эксперименты по распознаванию образов с использованием разработанных моделей KAN и аналогичных моделей MLP.
- Сравнить результаты работы усовершенствованных моделей KAN и MLP для определения их эффективности в условиях непрерывного обучения и проявления катастрофического забывания.

- Проанализировать полученные экспериментальные данные и сделать выводы о потенциале использования сетей Колмогорова-Арнольда в задачах непрерывного обучения.

Обзор литературы

Глава 1. Анализ существующих подходов к преодолению катастрофического забывания

Здесь будут рассмотрены четыре основных подхода к изменению архитектуры MLP, используемых для смягчения влияния катастрофического забывания. Для каждого из подходов будут описаны представители, сравнение эффективности которых с аналогами на базе архитектуры KAN будет произведено в главе "анализ экспериментов".

1.1 Подход с использованием ансамблирования

1.2 Подход с использованием регуляризации

1.3 Подход с использованием разреженного кодирования представлений

1.4 Подход с воспроизведением опыта

Глава 2. Построение усовершенствованных моделей на базе архитектуры KAN

Здесь будут описаны изменения, внесённые в архитектуру KAN в соответствии с идеями каждого из рассмотренных в предыдущей главе подходов, а также описаны параметры и гиперпараметры, использованные в каждой из полученных моделей, так, чтобы стало возможным полное воспроизведение процесса усовершенствования.

- 2.1 Использование оригинальной архитектуры KAN**
- 2.2 Подход с использованием ансамблирования**
- 2.3 Подход с использованием регуляризации**
- 2.4 Подход с использованием разреженного кодирования представлений**
- 2.5 Подход с производением опыта**

Глава 3. Применение усовершенствованных моделей в задачах непрерывного обучения

Здесь будут описаны детали эксперимента с перестановкой данных (используется для оценки способности модели справляться с катастрофическим забыванием в условиях, когда данные изменяются, но сохраняют ту же структуру) и обучения с постепенным добавлением новых классов, а также приведены таблицы с результатами применения в них каждой из усовершенствованных моделей, полученных в предыдущей главе

3.1 Обучение с перестановкой данных

3.2 Инкрементальное обучение классам

Глава 4. Анализ экспериментов

Здесь будет произведён анализ результатов полученных моделей как между собой (как представителей одной архитектуры), так и с результатами соответствующих аналогов (полученных с использованием тех же подходов) на базе архитектуры MLP.

4.1 Сравнение усовершенствованных моделей на базе архитектуры KAN

4.2 Сравнение эффективности подходов применительно к архитектурам KAN и MLP

Выводы

Заключение

Список литературы

Приложение